Algoritmi za detekciju plagijarizma sa implementacijom algoritma zasnovanog na n-gramima

Seminarski rad u okviru kursa
Metodologija stručnog i naučnog rada
Matematički fakultet

Nemanja Subotić, Igor Rodić
suboticnemanja93@gmail.com, igorrodic@gmail.com

2. maj 2016.

Sažetak

Sa pojavom modernih tehnologija, pre svega interneta, svet je postao u velikoj meri izložen raznim oblicima zloupotreba. Jednu od tih zloupotreba predstavljaju plagijarizmi. Osnovnu zaštitu predstavljaju računarski algoritmi za detekciju plagijarizma, jer je, s obzirom na količinu dostupnih podataka, za čoveka u velikom broju slučajeva to nemoguće. Tema i cilj rada je prikazivanje osnovnih ideja i pristupa pri impelementaciji ovih algoritama, kao i detaljnijeg opisa i implementacije algoritma za detekciju plagijarizma tekstova na engleskom. Ovaj algoritam zastupa jedan neobičan pristup i u praksi daje dobre rezultate, u nekim slučajevima čak i najbolje.

Sadržaj

1 Uvod

Postoje mnoge definicije plagijarizma, ni jedna nije sasvim precizna, pre svega zato što plagijarizam predstavlja nešto drugo za svakoga od nas. Definicija koja stoji u Kembridžovom rečniku (eng. *Cambridge English Dictionary* [9]) glasi:

Definicija 1.1 *Plagirati: koristiti tuđe ideje i praviti se da su vaše.*

Osnovu za detekciju plagijarizma predstavljaju računari i efikasni algoritmi koji su u tu svrhu implementirani. U ovom radu čitaocu su predstavljene osnove pisanja algoritama za njihovu detekciju, kao i detaljniji opis algoritma za detekciju plagijarizma teksta, zasnovanog na n-gramima. Prvo su opisane ideje i pristupi, kao i klasifikacija algoritama za detekciju plagijarizma (3). Zatim su u sledećoj sekciji opisani mogući načini sakrivanja plagijarizma, kao i načini da te metode budu otkrivene (2). Na kraju, implementiran je algoritam teksta zasnovan na n-gramima (4).

2 Sakrivanje plagijarizma

U ovoj sekciji biće reči o tehnikama sakrivanja plagijarizma, sa ciljem težeg otkrivanja, kao i tehnikama za njihovo otkrivanje i prevazilaženje.

Kada je u pitanju tekst neke od tehnika za sakrivanje plagijarizma su parafraziranje, korišćenje sinonima, prevođenje na drugi jezik, pa zatim nazad u početni itd. Kada je u pitanju programski kod definisani su nivoi modifikacije koji daju uvid u načine na koje plagijarizam može da bude sakriven [5]:

- Izmena komentara
- Izmena belina
- Preimenovanje identifikatora
- Izmena rasporeda blokova koda
- Izmena rasporeda naredbi unutar blokova
- Izmena redosleda operatora/operanada u izrazima
- Izmena tipova podataka
- Dodavanje redundantnih naredbi ili promenljivih
- Menjanje naredbi kontrole toka ekvivalentnim naredbama kontrole toka (while u do-while itd.)
- Menjanje poziva funkcije sa telom funkcije

Navedene tehnike sakrivanja plagijarizma prevazilaze se pretprocesiranjem. Pretprocesiranje predstavlja modifikovanje fajla pre same primene algoritma za detekciju plagijarizma. U sekcijama 2.1 i 2.2 opisane su tehnike pretprocesiranja teksta, i programskog koda.

2.1 Pretprocesiranje teksta

Tehnike pretprocesiranja teksta su WSD i Thesauri, i parseri. Menjanje reči sinonimima skoro je nemoguće otkriti bez pomoći računara. Na njima se taj problem rešava tokenizacijom, jedan od takvih softvera je i WordNet [2] (Thesaurus). Ali, pre nego što se uradi zamena svih sinonima jednom rečju, prvo mora biti primenjen WSD (eng. *Word Sense Disambiguation*) metod koji određuje značenje reči u zadatom kontekstu,

i tek onda može da bude primenjen tokenizator. Još jedna primena WSD metoda je pri otkrivanju plagijarizma ideje, kada se WSD koristi u kombinaciji sa drvetom konceptualnih klasa, ulazni fajl šalje se na semantičku analizu i dobija se lista klasa, umesto originalnih reči. Lista se dalje procenjuje pomoću uobičajnih algoritama detekcije plagijarizma.

Parseri se, sa druge strane, koriste kada je izmenjena struktura teksta (izmenjen redosled reči itd.). Oni dele rečenice na manje sekvence koji oslikavaju strukturu teksta, npr. parser može da prepozna homogene delove rečenice i da ih sortira leksikografski.

2.2 Pretprocesiranje programskog koda

Pretprocesiranje programskog koda deli se na dve tehnike, tokenizaciju i parametrizovano poklapanje. Tokenizacija pretvara programski kod u niz tokena, time ga spuštajući na gradivni nivo (predstavljajući promenljive, pozive funkcija, naredbe itd.) i eliminišući većinu načina skrivanja. Složenost procesa tokenizacije je linearna, stoga ona ne utiče na kompleksnost finalnog algoritma, medjutim, samim procesom mogu da se izgube važne informacije o sličnostima dva programa. U cilju očuvanja te sličnosti tokenizator se koristi zajedno sa parametrizovanim poklapanjem. Parametrizovano poklapanje smatra dva koda identičnim ako jedan može da se dobije iz drugog primenom konačnog broja zamena identifikatora.

3 Ideje i pristupi

Prva stvar o kojoj treba diskutovati jeste klasifikacija sistema za detekciju plagijarizma. Ona je, prirodno, za svakoga drugačija. Osnovna podela, prema Mozgovoju (eng. *Maxim Mozgovoy*) [8] deli pomenute sisteme na dve podgrupe, na sisteme koji prave otisak prsta (eng. *fingerprint*) dokumenta i na sisteme koji porede sadržaj [1].

Otisak prsta dokumenta predstavlja kratku sekvencu bajtova koja karakterizuje duži dokument. On može da se dobije primenom heš (eng. *hash*) funkcije na dokument, ali obično se koristi niz numeričkih atributa (prosečan broj reči po liniji, prosečan broj ključnih reči itd.), i zatim se pomoću funkcije razdaljine računa stepen različitosti dva dokumenta. Ova tehnika se danas retko koristi jer čak i male promene mogu da rezultuju potpuno drugačijim otiscima.

Poređenje sadržaja predstavlja osnovu za veliku većinu sistema za detekciju plagijarizma. Ono je generalno zasnovano na Manberovoj (eng. *Udi Manber*) definiciji sličnosti [7] i deli se na dve podvrste, na poređenje stringova i na drveta parsiranja.

Definicija 3.1 *Manberova definiciji sličnosti: Kažemo da su dva fajla slična ako sadrže značajan broj istih podniski koje nisu prekratke.*

Algoritmi za poređenje sadržaja funkcionišu po istom principu:

```
FOR EACH collection file F
  FOR EACH collection file G, F =/= G
    Calculate similarity between F and G
```

dok se funkcija za određivanje sličnosti menja. Kada pričamo o poređenju stringova pod time podrazumevamo poređenje fajlova, koji se tretiraju kao veliki stringovi. Ovaj način poređenja ne čuva strukturu fajlova, kao ni programskog koda. Algoritmi koji koriste ovaj način detekcije su: FPDS [6], koji računa sličnost po formuli:

```
sim(F, G) = MatchedTokens(F, G) / TotalTokens(G)
```

YAP [11] (jedan od prvih algoritama ove vrste, koristi poređenje liniju-po-liniju Levenštajnovim rastojanjem [4]), RKR-GST koji je implementiran u sistemu YAP3 [12] (pravi pokrivač nepreklapajućih stringova koji sadrže maksimalan mogući broj tokena iz oba fajla, algoritam je NP kompletan pa zavisi od uspešnih heuristika, npr. duže podniske su vrednije od kraćih).

Drveta parsiranja sa druge strane čuvaju strukturu fajla, kako tekstualnog (poglavlja, pasusi itd.) tako i programskog (klase, funkcije itd.). Prednosti ovog metoda poređenja još nisu u potpunosti iskorišćene, jedan od algoritama koji to pokušava je Sim utility [3]. On koristi poređenje stringova, ali ne nad celim fajlovima, već nad njihovim drvetima parsiranja, tj. parser prethodi algoritmu poređenja stringova.

4 Implementacija algoritma za detekciju plagijarizma teksta

U ovom delu opisaćemo metod za detekciju pagijarizma tekstova na engleskom jeziku korišćenjem n-grama stop-reči (eng. stopwords). Autor ovog metoda je grčki profesor sa Egejskog univerziteta, Estatios Stamatatos (eng. *Efstathios Stamatatos*) i metod je objavljen 2011. godine [10]. Pre nego što krenemo sa opisom algoritma, objasnimo prvo osnovne pojmove: n-gram predstavlja niz od n susednih stavki u tekstu, gde stavke mogu biti karakteri ili reči, dok stop-rečima smatramo najčešće korišćene reči nekog jezika (u našem slučaju engleskog).

Stop-reči su se pokazale veoma korisnim u istraživanju teksta u slučajevima kad je bitniji stil pisanja od sadržaja (npr. pripisivanju autorstva i detekcije žanra). Pa tako i profesor Stamatatos predstavlja novi metod detekcije plagijarizma koji je zasnovan isključivo na strukturnim informacijama. Umesto da eliminiše stop-reči, kao što je uobičajena praksa, iz teksta eliminiše sve ostale tokene i metod bazira na preostalom nizu stop-reči. Najčešći način plagiranja je zamena reči i izraza sinonimima. Pošto su stop-reči nezavisne od sadržaja i ne nose nikakve semantičke informacije, sekvence stop-reči često ostaju nepromenjene prilikom manjih izmena teksta.

4.1 Opis algoritma

Autor je metod podelio na tri dela. U prvom delu se određuje da li je sumnjivi dokument plagijat ili ne. Nakon toga, trebalo bi pronaći sve plagijarizovane delove, odrediti njihove granice i u sumnjivom i u izvornim dokumentima. Na kraju je poželjno za svaki plagijarizovani deo koji smo pronašli odrediti koeficijent plagijarizma.[10]

Reprezentacija teksta se zasniva na n-gramima stop-reči (SWNG eng. stopword n-gram). Za dati dokument i listu stop-reči tekst dokumenta se transformiše na sledeći način: prvo se velika slova prevedu u mala, zatim se vrši tokenizacija i svi tokeni koji se ne nalaze u listi stop-reči se izbacuju, na kraju se grade n-grami. Ovaj skup n-grama stop-reči nazivamo profil dokumenta - $P(n, d)$.

Profesor Stamatatos kao stop-reči koristi pedeset najčešće korišćenih reči engleskog jezika (1) prema Britanskom nacionalnom korpusu.

Tabela 1: 50 najčešćih stop-reči u engleskom jeziku.

1. the	11. with	21. are	31. or	41. her
2. of	12. he	22. not	32. an	42. n't
3. and	13. be	23. his	33. were	43. there
4. a	14. on	24. this	34. we	44. can
5. in	15. i	25. from	35. their	45. all
6. to	16. that	26. but	36. been	46. as
7. is	17. by	27. had	37. has	47. if
8. was	18. at	28. which	38. have	48. who
9. it	19. you	29. she	39. will	49. what
10. for	20. 's	30. they	40. would	50. said

4.2 Određivanje kandidata

Prvi korak je izdvajanje skupa izvornih dokumenata, čiji elementi imaju delove koji su verovatno plagijarizovani u sumnjivom dokumentu. Ovo zahteva poređenje sumnjivog dokumenta sa svim izvornim dokumentima koje imamo kako bi se pronašla bilo kakva lokalna sličnost.

Cilj je pronaći zajednički n-gram stop-reči sumnjivog i svakog izvornog dokumenta. Najvažnije je odrediti odgovarajuću vrednost za n, tj. odrediti kolika bi trebala da bude dužina niza uzastopnih stop-reči da bi se otkrila sličnost između sumnjivog i izvornog dokumenta. Recimo da je to vrednost n_1, tada za svaki zajednički n-gram između para dokumenata gde je $n < n_1$ poklapanje se smatra neznačajnim, dok za svaki zajednički n-gram između para dokumenata gde je $n \geq n_1$ sugeriše na plagijarizam. Vrednost n_1 bi trebala biti relativno visoka, ali trebalo bi imati u vidu da pri znatnim promenama teksta dužina niza uzastopnih reči neće biti velika.

Problem predstavlja slučaj kada se pronađe zajednički n-gram sumnjivog i izvornog dokumenta koji pripadaju delovima koji su semantički različiti, što uvećava broj lažno pozitivnih plagijarizovanih delova. To je obicno slučaj kada zajednički n-gram sadrži samo veoma česte stop-reči, u engleskom jeziku, to su prvih šest najčešćih stop-reči(the, of, and, a, in, to) i 's. Da bi izbegao ovaj slucaj, autor metoda, uvodi ograničenje na sadržaj zajedničkog n-grama. Neka je $C = \{the, of, and, a, in, to, `s\}$ skup stop-reči koje se obicno pojavljuju u slučajnim pogocima. Neka je D_x skup sumnjivih dokumenata koje želimo da ispitamo, a D_s skup izvornih dokumenata i da $d_x \in D_x$ i $d_s \in D_s$, dok su $P(n_1, d_x)$ i $P(n_1, d_s)$ odgovarajući profili ovih dokumenata koji sadrže n-grame stop-reči dužine n_1. Tada je detektovan plagijarizam ukoliko je zadovoljen sledeći kriterijum :

$$\exists g \in P(n_1, d_x) \cup P(n_1, d_s) : member(g, C) < n_1 - 1 \wedge maxseq(g, C) < n_1 - 2$$

gde je $member(g, C)$ funkcija koja vraća broj stop-reči n-grama g koji pripadaju skupu C, a $maxseq(g, C)$ funkcija koja vraća maksimalnu sekvencu stop-reči u g, koji pripadaju C.

4.3 Određivanje granica delova

Nakon što je pronađen skup izvornih dokumenata koji se poklapaju sa sumnjivim, potrebno je odrediti granice sličnih delova teksta u svakom od ovih dokumenata. Neka je $D_{rx} \subseteq D_s$ skup dokumenata izdvojenih

u prethodnom koraku. Naš cilj je pronalaženje svih g takvih da je $g \in P(n, d_x) \cup P(n, d_s)$ pri čemu je $d_s \in D_{rx}$, a nakon toga i građenje sekvenci maksimalne dužine od pronađenih g, tako da svaka dobijena sekvenca predstavlja plagijarizovani deo teksta. Granice delova nam predstavljaju početni i krajnji n-grami u dobijenim sekvencama.

Poklapanje n-grama sumnjivog i izvornog dokumenta može se predstaviti dijagramom rasipanja. Na slici (1) prikazan je primer doslovnog plagijarizma, kao i primer plagijarizma nastalog izmenama izvornog dokumenta (2). Broj praznina i grupa na dijagramu rasipanja zavisi od vrednosti n, tj. reda n-grama korišćenog u kreiranju profila dokumenata. Što je n veće, imaćemo više praznina i grupa.

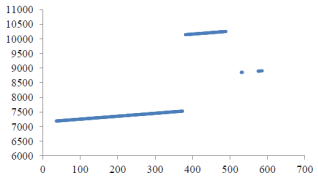

Slika 1: Dijagram rasipanja poklopljenih n-grama u slučajevima doslovnog plagijarizma.

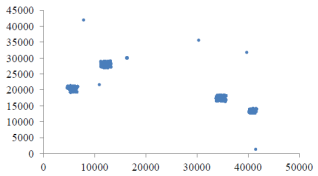

Slika 2: Dijagram rasipanja poklopljenih n-grama u slučajevima kada je plagijarizovani pasus pretežno modifikovan.

U prethodnom koraku, da bi utvrdio sličnosti između para dokumenata, autor je koristio duže n-grame (reda n_1), ali za određivanje granica potrebni su mu kraći n-grami (reda $n_2 < n_1$) da bi imao detaljnije poređenje. I ovde se dodaje uslov za izbegavanje slučajnih poklapanja n-grama, samo što je uslov malo blaži da bi praznine između zajedničkih n-grama bile manje. Neka su $P(n_2, d_x)$ i $P(n_2, d_s)$ profili sumnjivog i izvornog dokumenta koji sadrže n_2-grame stop-reči. Zajednički n_2-gram g je pronađen ako je zadovoljen sledeći uslov:

$$g \in P(n_2, d_x) \cup P(n_2, d_s) : member(g, C) < n_2$$

Neka je $M(d_x, d_s)$ skup zajedničkih n-grama između profila P(n_2, d_x) i $P(n_2, d_s)$. Na primer, ukoliko je $(17, 9) \in M$, to znaci da sedamnaesti n_2-gram u d_x odgovara devetom n_2-gramu u d_s. Članovi skupa M su poređani na osnovu prvog pojavljivanja u tekstu. Skup M možemo podeliti na dva dela M_1 i M_2, tako da odgovaraju, redom, sumnjivom i izvornom dokumentu. Uzastopne vrednosti u M_1 su rastuće dok u M_2 mogu biti i opadajuće. Granice plagijarizovanih delova teksta povezane su sa velikim promenama susednih vrednosti u skupovima M_1 i M_2, što se može videti na slikama (1) (2).

Pri određivanja granica problem nam može predstavljati slučaj kada imamo više plagijarizovanih delova teksta koja su relativno blizu, dok su odgovarajući originalni delovi u izvornom dokumentu udaljeni, kao i suprotno. U opisu metoda, predloženo je sledeće rešenje [10] : Prvo odrediti početni skup granica u sumnjivom dokumentu, tj. podeliti skup M na osnovu razlika susednih vrednosti u M1, pri čemu su dozvoljene manje praznine. Zatim, granice u izvornom dokumentu odrediti tako što se dobijeni skupovi podele na osnovu razlika susednih vrednosti u M_2, gde bi takođe trebalo dozvoliti manje praznine. I na kraju konačni skup granica u sumnjivom dokumentu odrediti na osnovu dobijenih granica u izvornom dokumentu.

4.4 Određivanje koeficijenta plagijarizma

Svaka detekcija plagijarizma može se predstaviti kao uređena četvorka $< t_x, d_x, t_s, d_s >$, gde t_x predstavlja plagijarizovan deo teksta u sumnjivom dokumentu d_x, koji odgovara delu teksta t_s u izvornom dokumentu d_s. Da bi odredio koeficijent plagijarizma, autor metoda, koristi karakterske n-grame. Prvo se vrši normalizacija delova t_x i t_s, tako što se sva velika slova zamene malim i izbace svi interpunkcijski znaci. Zatim se sličnost između njih računa po sledećoj formuli:

$$Sim(t_x, t_s) = \frac{|P_c(n_c, t_x) \cap P_c(n_c, t_s)|}{max(|P_c(n_c, t_x)|, |P_c(n_c, t_s)|)}$$

gde su $P_c(n_c, t_x)$ i $P_c(n_c, t_s)$ karakterski n_c-grami profili delova t_x i t_s. Izbor vredonsti za n_c zavisi od toga koliko želimo da merenje bude fleksibilno. Što su duži karakterski n-grami to je veća verovatnoća da se izmene neće detektovati kao plagijarizam.

4.5 Prednosti, rezultati i parametri

Profesor Stamatatos navodi da nije moguće odrediti jedinstvenu vrednost dužine n-grama koja daje najbolje rezultate, ona zavisi od toga šta nam u konkretnom slučaju treba, kao i od raspoloživih resursa (snage računara, memorije itd.). Nakon potpune implementacije algoritma testirano je kako različite dužine n-grama utiču na rezultate detekcije plagijarizma. Testirane su samo različite vrednosti za n jer se pokazalo da menjanje vrednosti m (granice za rupe u plagijatu) ne utiče presudno na rezultate. Takođe, bez obzira na vrednost n, dokumenti koji nisu plagijati su tako i okarakterisani, te nisu uneti u tabelu sa rezultatima (2). Iz tabele se vidi da je 8 otprilike prelomna granica za detekciju, i da bi to bio dobar izbor za n.

Tabela 2: Rezultati primene algoritma sa n-gramima.

n	100_plag	80_plag	60_plag	40_plag	20_plag	modified_plag
6	100%	83.9506%	62.963%	41.9753%	22.2222%	72.8395%
7	100%	83.9506%	62.963%	41.9753%	22.2222%	72.8395%
8	100%	83.9506%	62.963%	40.7407%	22.2222%	70.3704%
9	100%	82.716%	61.7284%	39.5062%	20.9877%	69.1358%
10	100%	81.4815%	60.4938%	38.2716%	20.9877%	65.4321%

5 Zaključak

Svakim danom broj javno dostupnih dokumenata, a samim tim i broj plagijarizma, sve je veći. Uporedo, razvijaju se i algoritmi za detekciju plagijarizma kako teksta, tako i programskog koda. Algoritam grčkog profesora Estatiosa Stamatatosa zasnovan na n-gramima stop-reči za detekciju plagijarizma teksta je zanimljiv jer uvodi jedan novi pristup, ali i sadrži u sebi neke prethodne. Trebalo bi pokušati modifikovati algoritam i primeniti ga za detekciju plagijarizma programskog koda, kao i uvesti brojne modifikacije koje se tiču vremenske složenosti, jer je mogućnost da se obradi velika količina dokumenata ključni faktor kada su u pitanju algoritmi detekcije plagijarizma.

Literatura

[1] Georgina Cosma and Mike Joy. An approach to source-code plagiarism detection and investigation using latent semantic analysis. *IEEE Trans. Computers*, 61(3):379–394, 2012.

[2] C. Fellbaum, editor. *Wordnet, an Electronic Lexical Database*. MIT Press, 1998.

[3] David Gitchell and Nicholas Tran. Sim: a utility for detecting similarity in computer programs. In *Proc. Technical Symp. Computer Science Education (SIGCSE)*, pages 266–270. ACM Press, 1999.

[4] Rishin Haldar and Debajyoti Mukhopadhyay. Levenshtein distance technique in dictionary lookup methods: An improved approach. *CoRR*, abs/1101.1232, 2011.

[5] M. Luck M. Joy. Plagiarism in Programming Assignments. *IEEE Transactions on Education*, 1999.

[6] D. White etal M. Mozgovoy, K. Fredriksson. Fast Plagiarism Detection System, Lecture Notes in Computer Science, 2005.

[7] Udi Manber. Finding similar files in a large file system. In *Proc. Winter Usenix Technical Conf.*, pages 1–10, 1994.

[8] M. Mozgovoy. *Enhancing Computer-Aided Plagiarism Detection*. PhD thesis, University of Joensuu, Joensuu, Finland, 2007.

[9] Rationality. *Cambridge Advanced Learner's Dictionary*. Cambridge University Press, 2005.

[10] Efstathios Stamatatos. Plagiarism detection using stopword n-grams. *JASIST*, 62(12):2512–2527, 2011.

[11] Michael J. Wise. Detection of similarities in student programs: Yap'ing may be preferable to plague'ing. In Nell B. Dale, editor, *SIGCSE*, pages 268–271. ACM, 1992.

[12] Michael J. Wise. Yap3: improved detection of similarities in computer program and other texts. In John Impagliazzo, Elizabeth S. Adams, and Karl J. Klee, editors, *SIGCSE*, pages 130–134. ACM, 1996.

A Dodatak

Pored ovog rada, u prilogu se nalaze i izvorni kod algoritma koji je implementiran.